

Segmentare de imagini

Alexandru Agape

24 Aprilie 2012

1 Introducere

În această temă veți lua contact cu două domenii ale *computer science* aflate pe val, și anume *computer vision* și *machine learning*. Mulți dintre algoritmi învățați de voi la Proiectarea Algoritmilor sunt folosiți în rezolvarea problemelor ce țin de computer vision (sau mai general, a problemelor de machine learning aplicate și în computer vision). Inferența în modele probabilistice graf-reprezentabile [5] admite rezolvări prin metode greedy, programare dinamică, drumuri minime și flux maxim, și are numeroase aplicații. Una dintre acestea este segmentarea imaginilor, ce face subiectul temei. Chiar dacă vor fi menționate mai multe concepte specifice celor două domenii, rezolvarea temei nu este condiționată de înțelegerea acestora și nu ar trebui să vă sperie. Teoretic, secțiunea 4 reprezintă un enunț suficient al temei, restul documentului oferind doar explicații suplimentare și o motivare succintă a formulelor de calcul. Veți constata însă că seminarele de matematică din anul I nu au fost o pierdere de timp.

2 Segmentarea imaginilor

Aceasta presupune împărțirea unei imagini în multiple segmente după niște criterii. Sunt posibile numeroase abordări și interpretări ale problemei [13] (*clustering*-ul fiind adesea întâlnit). Noi vom modela însă problema folosind probabilități și distribuții de tip Gibbs [12].

Problema segmentării nu este o problemă bine definită (ill-posed problem): nu există (decât rareori) un răspuns corect, doi oameni construind soluții diferite pentru o imagine dată. O primă cauză ar fi faptul că o imagine

poate fi segmentată atât în trei-patru regiuni mari cât și în o sută de segmente foarte mici, în funcție de răbdarea și raționamentul celui care adnotează. Pentru a face lucrurile mai clare ne vom concentra atenția pe extragerea unui singur segment reprezentând obiectul/obiectele din prim-plan, restul imaginii considerându-l a fi fundal. Acest caz particular se numește segmentare binară sau foreground-background.

3 Modelarea problemei

Extragerea segmentului principal din imagine poate fi văzută ca a asigura fiecărui pixel din imagine o valoare **true** sau **false** după cum aparține sau nu segmentului respectiv. Vom defini deci pentru fiecare pixel o variabilă aleatoare $X_i = x_i \in \{0, 1\}$. Notând cu N numărul total de pixeli din imagine vom avea deci 2^N posibilități de a asigura valori variabilelor (numite în continuare configurații), și deci tot 2^N posibile segmentări ale imaginii. Dintre toate acestea, trebuie aleasă însă cea mai bună, după niște criterii date.

3.1 Modelul probabilistic

Vom construi o distribuție de probabilități peste spațiul exponențial de soluții. Vom folosi modelul Gibbs $\tilde{p}(x) = e^{-E(x)}$ pentru a modela probabilitatea ca o anumită configurație $x = x_1 x_2 \dots x_N$ să reprezinte segmentul principal (foreground). Vom considera drept soluție configurația cu cea mai mare probabilitate sub modelul ales. Datorită monotonicității funcției e^{-x} , probabilitatea maximă echivalează cu energia minimă. Să vedem cum putem modela funcția de energie pentru a ne asigura că într-adevăr configurația cu energie minimă reprezintă o segmentare binară bună a imaginii.

3.1.1 Model independent

În primă fază vom considera un model în care cele N variabile aleatoare sunt independente. Altfel spus, pentru fiecare pixel, decizia dacă este sau nu din segmentul principal nu este influențată de decizia luată pentru vecinii săi. Vom construi atât pentru fundal cât și pentru prim-plan câte un model probabilistic simplu, și pe baza acestora vom construi funcția de energie. Considerând că $p_f(x_i)$ modelează probabilitatea unui pixel de a fi în prim-plan, ne interesează energia asociată cu aceasta într-un model de tip Gibbs, ce are valoarea $-\log p_f(x_i)$.

$$E_u(x) = \sum_{i=1}^N \{x_i \cdot (-\log p_{\textcolor{red}{f}}^i) + (1 - x_i)(-\log p_{\textcolor{red}{b}}^i)\} \quad (1)$$

$$E(x) = E_u(x) \quad (2)$$

Pentru a minimiza această energie, este de ajuns a alege pentru fiecare pixel acea variantă (foreground/background) ce are probabilitate mai mare.

3.1.2 Modelul complet

În funcție de modelul ales pentru $p_{\textcolor{red}{f}}^i$ și $p_{\textcolor{red}{b}}^i$, modelul anterior poate da rezultate multumitoare, dar în continuare este loc de mai bine. Se dorește renunțarea la presupunerea de independență. Dacă un pixel este fundal, atunci e foarte probabil ca un pixel alăturat, mai ales dacă este foarte asemănător, să fie și el tot fundal. Dorim deci să penalizăm aceste inconsistențe între pixeli vecini, lucru realizabil prin adăugarea unor noi termeni la energia configurației. Termenii noi sunt ponderați cu o constantă λ .

$$E_p(x) = \sum_{(i,j) \in \mathcal{N}} f_p^{ij}(x_i, x_j) \quad (3)$$

$$E(x) = E_u(x) + \lambda E_p(x) \quad (4)$$

3.2 Particularizarea modelului

Deși modelul a fost deja stabilit, numeroase alegeri ce influențează calitatea soluțiilor au rămas, și anume forma concretă a **probabilităților** $p_{\textcolor{red}{f}}^i$ și $p_{\textcolor{red}{b}}^i$ și a funcției f_p^{ij} .

3.2.1 Costul individual

Probabilitățile de apartenență la prim-plan și fundal se modelează similar: fiind dați niște pixeli marcați de utilizator ca fiind sigur din clasa respectivă putem construi un model de culoare al clasei de tip Gaussian [10]. Un astfel de model are doar doi parametri: μ - media valorilor și σ - deviația standard. Cei doi parametri pot fi calculați folosind formulele 6 respectiv 7. **Probabilitățile sunt apoi calculate folosind o distribuție normală ca în ecuația 5, unde argumentul x reprezintă culoarea pixelului în cauză.**

$$\mathcal{N}(x; \mu, \sigma) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2} \quad (5)$$

$$\mu = \frac{\sum_{i \in Mask} Image(i)}{|Mask|} \quad (6)$$

$$\sigma = \sqrt{\frac{\sum_{i \in Mask} (\mu - Image(i))^2}{|Mask|}} \quad (7)$$

Acesta este un model mult simplificat. Rezultate mult mai bune se obțin utilizând o combinație de distribuții gaussiene (*Gaussian Mixture Model* [11]) ce acoperă cazurile în care obiectul/fundalul nu este omogen, ci alcătuit din mai multe părți de culori diferite. Stabilirea parametrilor μ și σ pentru fiecare din componentele modelului este însă mult mai dificilă așa că ne vom mulțumi cu modelul simplificat. Dacă doriți însă să experimentați puteți simula un model GMM folosind marcaje individuale (pixeli selectati din imagine) pentru fiecare componenta a mixturii. Nu se cere și nu va fi punctată drept corectă o astfel de abordare.

Întrucât modelul este slab, pentru unii pixeli se poate întâmpla ca valoarea uneia din probabilități să fie foarte mică ducând la o valoare mare a logaritmului. De aceea aceste costuri se trunchează la o valoare UMAX=10. De asemenea, pentru simplificare e garantat ca în toate testele valoarea lui σ nu va fi 0.

3.2.2 Costul perechilor

Cel mai simplu mod de a defini funcția de penalizare este de a nu ține cont de culoarea celor doi vecini, și a penaliza egal orice neconcordanță (Ecuația 8). Energia astfel obținută este numită energie Ising (sau mai general Potts) iar modelul nostru probabilistic complet este un *Markov Random Field* [14]. Un model probabilistic mai puternic (cunoscut drept *Conditional Random Field*) se obține condiționând penalizarea de observație (culoarea pixelilor), prin folosirea unei funcții de tipul celei din ecuația 9. O vom folosi pe aceasta (prima variantă va fi doar un caz particular, pentru un *threshold* foarte mare). Vom considera ca vecini oricare doi pixeli învecinați pe verticală sau orizontală (sunt maxim 4 vecini pentru un pixel). Fiecare pereche de pixeli este considerată o singură dată.

$$f_p(x_i, x_j) = 1 - \delta(x_i, x_j) = \begin{cases} 1 & \text{daca } x_i \neq x_j \\ 0 & \text{altfel} \end{cases} \quad (8)$$

$$f_p^{ij}(x_i, x_j) = \begin{cases} 1 & \text{dacă } x_i \neq x_j \text{ și } |\text{Imagine}(i) - \text{Imagine}(j)| \leq \textit{threshold} \\ 0 & \text{altfel} \end{cases} \quad (9)$$

Deoarece funcția din ecuația 8 definește o metrică iar cea din ecuația 9 o pseudometrică, configurația ce minimizează energia din ecuația 4 poate fi calculată exact (nu doar o aproximație), cu toate că spațiul de căutare este unul exponențial.

4 Cerințe

4.1 Date de intrare

Programul vostru va citi datele de intrare din mai multe fișiere detaliate în continuare:

- **image.pgm**
 - fișier de tip pgm [1] conținând imaginea ce trebuie segmentată
- **mask_fg.pgm**
 - fișier de tip pgm conținând pixelii marcați de utilizator ca făcând parte din obiect (valori nenule)
 - pixelii respectivi vor fi folosiți pentru a calcula parametrii μ și σ pentru modelul obiectului (se folosesc valorile din imagine a pixelilor marcați în mască)
- **mask_bg.pgm**
 - fișier de tip pgm conținând pixelii marcați de utilizator ca făcând parte din fundal (valori nenule)
 - pixelii respectivi vor fi folosiți pentru a calcula parametrii μ și σ pentru modelul fundalului (se folosesc valorile din imagine a pixelilor marcați în mască)

- **parametri.txt**
 - fișier text conținând diverși parametri **de tip întreg**, câte unul pe linie
 - parametri incluși: λ (vezi ecuația 4), *threshold* (vezi ecuația 9).
- observații fișiere pgm
 - toate fișierele sunt de tip *plain* (magic number *P2*)
 - fișierele nu conțin comentarii
 - valoarea lui *Maxval* este întotdeauna 255
 - în Windows pot fi deschise cu *gimp*

4.2 Ieșire

Programul vostru va crea fișierul **segment.pgm** valid, fără comentarii, având *Maxval* = 255 și dimensiunile imaginii egale cu cele ale imaginii de intrare. Pentru fiecare pixel considerat a fi fundal se va afișa valoarea 0, iar pentru pixelii obiect valoarea 255. Vom verifica dacă segmentarea dată de voi produce o configurație pentru care energia este minimă, **cu o precizie de 2 zecimale** (în caz că există mai multe soluții oricare este bună).

4.3 Detalii de implementare

Trebuie să scrieți un program care calculează configurația $x = x_1x_2...x_N$ ce minimizează funcția din ecuația 10.

$$E(x) = \sum_{i=1}^N f_u^i(x_i) + \lambda \sum_{(i,j) \in \mathcal{N}} f_p^{ij}(x_i, x_j) \quad (10)$$

În continuare descriem variabilele ce apar în ecuație. Pentru prima sumă

avem (deduse din ecuațiile anterioare):

$$\begin{aligned}\tilde{f}_u^i(x) = x \cdot \left(\frac{1}{2}\left(\frac{\text{Image}(i) - \mu_f}{\sigma_f}\right)^2 + \log \sqrt{2\pi\sigma_f^2}\right) + \\ (1-x) \cdot \left(\frac{1}{2}\left(\frac{\text{Image}(i) - \mu_b}{\sigma_b}\right)^2 + \log \sqrt{2\pi\sigma_b^2}\right)\end{aligned}\quad (11)$$

$$f_u^i(x) = \min(\tilde{f}_u^i(x), 10) \quad (12)$$

$$\mu_f = \frac{\sum_{i \in Mask_f} Image(i)}{|Mask_f|} \quad (13)$$

$$\sigma_f = \sqrt{\frac{\sum_{i \in Mask_f} (\mu - Image(i))^2}{|Mask_f|}} \quad (14)$$

$$\mu_b = \frac{\sum_{i \in Mask_b} Image(i)}{|Mask_b|} \quad (15)$$

$$\sigma_b = \sqrt{\frac{\sum_{i \in Mask_b} (\mu - Image(i))^2}{|Mask_b|}} \quad (16)$$

$$(17)$$

Logaritmii care apar în aceste ecuații precum și în restul documentului sunt logaritmi naturali - au baza e (sunt derivate din logaritmarea unor exponențiale). În $C++$ și $Java$ puteți deci folosi funcția `log` din `math.h` respectiv `java.lang.Math` fără alte scalări.

Pentru ce-a dea doua sumă, deduse din ecuațiile anterioare, avem relațiile:

$$f_p^{ij}(x_1, x_2) = \begin{cases} 1 & \text{dacă } x_1 \neq x_2 \text{ și } |Image(i) - Image(j)| \leq threshold \\ 0 & \text{altfel} \end{cases} \quad (18)$$

$$\mathcal{N} = \{(i, j) | 1 \leq i < j \leq N \text{ și } i \text{ adjacent } j\} \quad (19)$$

4.3.1 Hint 1

Deși nu sunteți constrânși în a proceda astfel, puteți afla configurația minimă aplicând und algoritm de flux maxim (tăietură minimă).

4.3.2 Hint 2

Graful se poate construi astfel: fiecare pixel este un nod, există muchii doar între pixeli vecini (\mathcal{N} devine mulțimea muchiilor) și acestea au capacități

proportionale cu valoarea lui $f_p^{ij}(0, 1) = f_p^{ij}(1, 0)$ pentru pixelii respectivi. Suplimentar, apar două noi noduri f și g de care se leagă toate celelalte noduri prin muchii ale căror capacități modelează costurile unare $f_u^i(1)$ respectiv $f_u^i(0)$. Graful este neorientat. O tăietură minimă în acest graf este echivalentă cu o configurație ce minimizează funcția de energie: dacă o muchie $f - i$ face parte din tăietură atunci muchia $i - g$ nu este în tăietura minimă iar pixelul corespunzător nodului i este din segmentul principal. Fluxul maxim (și capacitatea tăieturii) este egal cu valoarea minimă a energiei: pentru orice pixel i din prim-plan, muchia $f - i$ face parte din tăietură iar la energie se adaugă termenul $f_u^i(1)$ dar nu și $f_u^i(0)$, și similar pentru pixelii din fundal; pentru doi pixeli vecini ce primesc aceeași valoare (ori fundal ori prim-plan) nu se taie nicio muchie, dar nici la energie nu se adună nimic ($f_p^{ij}(x, x) = 0, \forall x \in \{0, 1\}$); dacă cei doi vecini primesc valori diferite, de exemplu $x_i = 1$ și $x_j = 0$ atunci muchia $i - j$ având capacitatea $f_p^{ij}(1, 0)$ face parte din tăietură.

4.4 Punctare

Pentru 5 puncte din 8 programul vostru trebuie să dea rezultate corecte pe imagini având un număr total de pixeli $N \leq 2100$. Pentru toate cele 8 puncte trebuie ca programul să ruleze pentru $N \leq 50000$ (atenție la memorie, nu e permis să utilizați mai mult de 64MB). Vor apărea ulterior informații suplimentare despre limitele de timp în funcție de limbajul de programare.

5 Aprecieri

Dacă vreți să aflați mai multe despre cele două domenii introduse — *computer vision* și *machine learning*, vă recomandăm să urmați cursurile *Coursera* predate de doi profesori renumiți ce se desfășoară în această perioadă ([7] și [6]).

Pentru mai multe informații despre segmentarea imaginilor în general puteți consulta articolele științifice [2], [9], [4], [3] sau [8].

6 Revizii ale documentului

- **24.04.2012** Versiunea inițială
- **27.04.2012** Corectare cost individual (când σ este foarte mic).

- **1.05.2012** Precizare baza logaritm.
- **2.05.2012** Corectie ecuatia 11; probabilitatea ca un pixel sa fie foreground depinde de culoarea pixelului.

Cuprins

1	Introducere	1
2	Segmentarea imaginilor	1
3	Modelarea problemei	2
3.1	Modelul probabilistic	2
3.1.1	Model independent	2
3.1.2	Modelul complet	3
3.2	Particularizarea modelului	3
3.2.1	Costul individual	3
3.2.2	Costul perechilor	4
4	Cerințe	5
4.1	Date de intrare	5
4.2	Ieșire	6
4.3	Detalii de implementare	6
4.3.1	Hint 1	7
4.3.2	Hint 2	7
4.4	Punctare	8
5	Aprecieri	8
6	Revizii ale documentului	8

Referințe

- [1] Pgm file type. <http://netpbm.sourceforge.net/doc/pgm.html>.
- [2] Yuri Boykov and Gareth Funka-Lea. Graph cuts and efficient n-d image segmentation.
- [3] Yuri Boykov and Marie-Pierre Jolly. Interactive graph cuts for optimal boundary and region segmentation of objects in n-d images. In *ICCV*, pages 105–112, 2001.
- [4] Yuri Boykov and Vladimir Kolmogorov. An experimental comparison of min-cut/max-flow algorithms for energy minimization in vision. *IEEE Trans. Pattern Anal. Mach. Intell.*, 26(9):1124–1137, 2004.
- [5] Daphne Koller. Probabilistic graphical models. <https://www.coursera.org/course/pgm>.
- [6] Jitendra Malik. Computer vision: The fundamentals. <https://www.coursera.org/course/vision>.
- [7] Andrew Ng. Machine learning. <https://www.coursera.org/course/ml>.
- [8] Carsten Rother, Vladimir Kolmogorov, and Andrew Blake. "grabcut": interactive foreground extraction using iterated graph cuts. *ACM Trans. Graph.*, 23(3):309–314, 2004.
- [9] Richard Szeliski, Ramin Zabih, Daniel Scharstein, Olga Veksler, Vladimir Kolmogorov, Aseem Agarwala, Marshall F. Tappen, and Carsten Rother. A comparative study of energy minimization methods for markov random fields with smoothness-based priors. *IEEE Trans. Pattern Anal. Mach. Intell.*, 30(6):1068–1080, 2008.
- [10] Wikipedia. Gaussian distribution. http://en.wikipedia.org/wiki/Normal_distribution.
- [11] Wikipedia. Gaussian mixture model. http://en.wikipedia.org/wiki/Mixture_model.
- [12] Wikipedia. Gibbs distribution. http://en.wikipedia.org/wiki/Boltzmann_distribution.

- [13] Wikipedia. Image segmentation. [http://en.wikipedia.org/wiki/Segmentation_\(image_processing\)](http://en.wikipedia.org/wiki/Segmentation_(image_processing)).
- [14] Wikipedia. Markov random field. http://en.wikipedia.org/wiki/Markov_random_field.